Famou-Scientist：第四章中文预览

1 Famou-Scientist：从目标澄清到自主研究循环

本文使用 Famou-Scientist 将自然语言形式的研究目标转化为可执行的算法发现过程。与直接要求大语言模型生成一个分类器不同，Famou-Scientist 首先通过 Deep Research 调查相关任务和已有方法，再澄清研究目标、选择 baseline 与 benchmark，并据此构造统一的 evaluator。之后，系统通过多轮“提出想法—实现—实验—分析”的循环逐步搜索候选算法。

1.1 框架概览与问题形式化

设用户输入的自然语言研究请求为 r，候选算法空间为 $\mathcal{A}$，数据和实验环境为 $\mathcal{D}$。在给定研究目标 $\mathcal{G}$ 的条件下，系统希望找到具有最佳评价结果的候选算法：

$$a^* = \arg\max_{a \in \mathcal{A}} S(a; \mathcal{D}, \mathcal{G}), \tag{1}$$

其中 S 表示由实验协议确定的评价函数。Famou-Scientist 并不直接从 r 生成 a^*，而是先调查并构造执行目标，再由目标驱动候选搜索。令 $\mathcal{P}$ 表示 Deep Research 得到的任务证据和方法选项，则这一过程可抽象为：

$$\mathcal{P} = \mathcal{R}_\phi(r), \qquad \mathcal{G} = \mathcal{C}_\phi(r, \mathcal{P}), \qquad \mathcal{E}_\mathcal{G} = \mathcal{V}_\phi(\mathcal{G}, \mathcal{P}), \tag{2}$$

其中 $\mathcal{R}_\phi$ 表示 Deep Research，$\mathcal{C}_\phi$ 表示目标澄清过程，$\mathcal{V}_\phi$ 表示根据已确认目标构造 evaluator 的过程。得到 evaluator 后，第 t 轮候选及其结果分别为

$$a_t \sim \pi_\phi(\cdot \mid \mathcal{G}, \mathcal{H}_t), \qquad e_t = \mathcal{E}_\mathcal{G}(a_t), \tag{3}$$

其中 π_ϕ 表示候选生成过程，$\mathcal{H}_t$ 表示截至该轮的实验历史。该形式化将 Famou-Scientist 的前置工作与研究循环区分开来：前者确定“要解决什么问题、参考哪些方法以及如何评价”，后者搜索“用什么算法解决该问题”。

1.2 Deep Research 与目标澄清

自然语言研究请求通常不足以直接启动一个可靠的实验。例如，“寻找一个具有良好跨站点泛化能力的 MDD 分类器”并没有明确哪些方法应作为 baseline、使用哪个 benchmark、数据如何划分、哪些站点可以用于开发，以及使用什么评价指标。

Famou-Scientist 首先对请求进行 Deep Research。该过程检索任务相关的论文、数据集说明和已有实现，归纳常用的 baseline、benchmark、评价指标和实验协议，并将这些信息作为候选

方案及其依据提供给后续澄清过程。Deep Research 的作用不是直接决定实验设置，而是减少目标定义中的遗漏，并使后续选择建立在已有研究和任务惯例之上。

在此基础上，系统与用户共同确定可执行的研究目标：

$$\mathcal{G} = (\mathcal{D}_{\text{pub}}, \mathcal{S}, \mathcal{M}, \mathcal{B}, \mathcal{R}, \mathcal{B}_{\text{base}}, \mathcal{K}), \tag{4}$$

其中 $\mathcal{D}_{\text{pub}}$ 表示可访问的数据，$\mathcal{S}$ 表示数据划分和站点约束，$\mathcal{M}$ 表示评价指标，$\mathcal{B}$ 表示资源预算，$\mathcal{R}$ 表示输出和停止条件，$\mathcal{B}_{\text{base}}$ 表示选定的 baseline 集合，$\mathcal{K}$ 表示 benchmark 合约。对于本文的跨站点 MDD 分类任务，澄清过程需要明确训练、开发和最终测试数据的使用边界，确定跨站点评价指标，选择具有代表性的比较方法，并规定候选程序可以修改的部分。

目标澄清完成后，Famou-Scientist 根据 $\mathcal{G}$ 和 Deep Research 结果自主构造 evaluator。该 evaluator 将数据读取、站点划分、baseline 运行、候选算法执行、指标计算和必要的有效性检查组织成一个统一的评价过程：

$$\mathcal{E}_{\mathcal{G}} : \mathcal{A} \to \mathbb{R} \times \mathcal{Z}, \tag{5}$$

其中第一项为候选算法的评价分数，$\mathcal{Z}$ 表示日志、诊断信息和失败原因等附加证据。Evaluator 在候选搜索开始前确定，从而避免系统为了适应某个候选结果而改变评价协议。信息缺失时，系统要求补充或确认关键假设，而不是让后续实现过程隐式地决定这些内容。

1.3 迭代式研究循环

在研究目标和 evaluator 确定后，Famou-Scientist 进入迭代式研究循环。设第 t 轮之前已经完成的实验历史为

$$\mathcal{H}_t = \{(a_i, e_i)\}_{i=1}^{t-1}, \tag{6}$$

其中 a_i 表示第 i 轮提出并实现的候选算法，e_i 表示对应的实验结果和分析信息。每一轮包含四个阶段。

提出想法。 系统根据当前研究目标、baseline、已有候选及历史实验结果提出新的算法机制。一个有效的想法应说明其改变了算法的哪一部分，以及为什么这种改变可能改善目标指标。搜索过程因此不局限于随机的超参数调整，也可以探索新的数据表示、特征构造、分类器结构和训练策略。

实现候选。 提出的算法机制被转换为可以运行的候选分类程序。候选程序遵守 benchmark 合约规定的输入输出约束，并使用统一的 evaluator，从而保证不同候选之间具有可比性。

运行与评价。 候选程序在固定的数据和评价协议下运行，系统记录其性能指标以及必要的实验诊断信息。候选算法可能取得较好的结果，也可能因为实现错误、资源超限或训练不稳定而失败。这些情况都被视为研究循环中的有效反馈。

分析与更新。 系统分析候选算法相对于 baseline 的结果，并据此决定下一轮是继续改进当前机制、探索新的方向，还是结合已有的多个机制。成功和失败的实验都会影响后续候选的生成，使研究过程从独立的单轮尝试转变为基于证据的连续搜索。

1.4 反馈驱动的候选搜索

研究循环的搜索状态由目标 $\mathcal{G}$、evaluator $\mathcal{E}_{\mathcal{G}}$ 和实验历史 $\mathcal{H}_t$ 共同决定：

$$a_t \sim \pi_\phi(\cdot \mid \mathcal{G}, \mathcal{E}_{\mathcal{G}}, \mathcal{H}_t), \qquad e_t = \mathcal{E}_{\mathcal{G}}(a_t), \tag{7}$$

并在评价结束后更新为：

$$\mathcal{H}_{t+1} = \mathcal{H}_t \cup \{(a_t, e_t)\}. \tag{8}$$

在实际搜索中，系统可以继续改进当前假设，也可以探索新的机制，或将互补的机制组合到同一个候选中。无论采取哪种方向，候选的提出依据、实现版本和实验结果都被保留在同一条研究历史中。这样，后续分析不仅可以比较最终分数，还可以回溯性能变化与算法机制之间的关系。达到预先设定的资源预算或停止条件后，循环结束并输出最终候选及其证据。

1.5 在跨站点 MDD 分类中的实例化

在本文中，Deep Research 用于识别 MDD 静息态影像分类中常见的 baseline、跨站点 benchmark 和评价指标；目标澄清阶段据此确定数据访问范围、站点划分、最终测试边界以及计算预算；随后由系统构造 evaluator，对 baseline 和搜索得到的候选算法执行一致的评价流程。候选算法空间 $\mathcal{A}$ 允许搜索不同的连接组表示、特征构造方式、分类器结构和训练策略。

Famou-Scientist 的任务不是在没有约束的情况下生成任意神经网络，而是在预先定义的科学问题、baseline 和评价边界内寻找具有更好跨站点泛化能力的分类程序。第五章将介绍具体的数据构建、benchmark、搜索范围和实验协议，第六章将报告研究循环实际发现的候选算法及其性能，并进一步分析哪些算法机制可能解释其跨站点表现。