Famou-Scientist：第四章中文预览

1 Famou-Scientist：从目标澄清到自主研究循环

本文使用 Famou-Scientist 将自然语言形式的研究目标转化为可执行的算法发现过程。与直接要求大语言模型一次性生成完整的方案代码不同，Famou-Scientist 首先通过与用户的多轮对话确定研究目标，再根据目标判断是否需要额外的任务知识、baseline、benchmark 和评价标准。必要时，系统在目标澄清过程中执行 Deep Research，并据此构造统一的 evaluator。目标确定后，系统通过多轮 “提出想法—实现—实验—分析” 的循环逐步搜索候选方案；用户还可以根据阶段性结果继续调整目标，使研究过程形成一个由用户反馈驱动的外层循环。

1.1 框架概览与问题形式化

设用户输入的自然语言研究请求为 r，候选方案空间为 $\mathcal{A}$，数据和实验环境为 $\mathcal{D}$。在给定研究目标 $\mathcal{G}$ 的条件下，系统希望找到具有最佳评价结果的候选方案：

$$a^* = \arg\max_{a \in \mathcal{A}} S(a; \mathcal{D}, \mathcal{G}). \tag{1}$$

式 (1) 中，S 表示由实验协议确定的评价函数。Famou-Scientist 并不直接从 r 生成 a^*，而是先通过对话识别目标，再按需补充任务知识并构造执行协议。令 $r_{0:k}$ 表示对话进行到第 k 轮时已经获得的信息，则目标构造过程可以抽象为：

$$g = \mathcal{C}_\phi(r_{0:k}), \qquad \mathcal{P} = \mathcal{R}_\phi(g), \qquad \mathcal{G} = \mathcal{F}_\phi(g, \mathcal{P}). \tag{2}$$

式 (2) 中，g 是对话中识别出的研究目标，$\mathcal{P}$ 是根据目标按需获得的任务证据，$\mathcal{G}$ 是最终的可执行目标。若目标已经包含足够的任务知识，则 $\mathcal{P}$ 可以为空；否则系统通过 Deep Research 补充相关论文、数据集说明和已有实现。该形式化强调 Deep Research 是目标澄清过程中的条件步骤，而不是与目标澄清并列的一级阶段。

1.2 目标澄清

自然语言研究请求通常不足以直接启动一个可靠的实验。例如，“寻找一个具有良好跨站点泛化能力的 MDD 分类器” 并没有明确用户究竟想优化什么、哪些数据可以使用、是否需要和已有方法比较，以及什么样的结果才足以支持结论。

Famou-Scientist 首先通过与用户的对话确定研究目标。澄清过程关注的是问题的科学含义，而不是立即选择某个模型。系统需要确认研究对象、预期输出、数据访问边界、评价重点和资源限制；当这些信息仍然不足时，系统继续提问或显式记录待确认的假设。用户也可以在看到初步

结果后指出目标偏差，例如要求更强调跨站点稳定性、降低模型复杂度，或改变对结果的解释重点。

在目标基本确定后，系统根据目标判断是否需要外部任务知识。例如，如果用户要求在一个已有大量研究的任务上寻找改进方法，系统需要进一步了解该任务中常用的 baseline、benchmark、评价指标和实验协议。此时 Deep Research 作为澄清过程的一个子步骤，检索相关论文、数据集说明和已有实现，并将结果整理为可供用户确认的选项。Deep Research 不直接决定实验设置，而是为目标澄清提供证据。

最终的执行目标可以表示为：

$$\mathcal{G} = (\mathcal{D}_{\text{pub}}, \mathcal{S}, \mathcal{M}, \mathcal{B}, \mathcal{R}, \mathcal{B}_{\text{base}}, \mathcal{K}),$$

其中 $\mathcal{D}_{\text{pub}}$ 表示可访问的数据，$\mathcal{S}$ 表示数据划分和站点约束，$\mathcal{M}$ 表示评价指标，$\mathcal{B}$ 表示资源预算，$\mathcal{R}$ 表示输出和停止条件，$\mathcal{B}_{\text{base}}$ 表示选定的 baseline 集合，$\mathcal{K}$ 表示 benchmark 合约。是否需要 baseline、benchmark 以及它们的具体形式，都由澄清后的研究目标决定，而不是由系统预先固定。

在 $\mathcal{G}$ 确定后，Famou-Scientist 根据目标和相关证据构造 evaluator：

$$\mathcal{E}_{\mathcal{G}} = \mathcal{V}_{\phi}(\mathcal{G}), \qquad \mathcal{E}_{\mathcal{G}} : \mathcal{A} \to \mathbb{R} \times \mathcal{Z},$$

其中 $\mathcal{V}_{\phi}$ 表示 evaluator 构造过程，第一项为候选方案的评价分数，$\mathcal{Z}$ 表示日志、诊断信息和失败原因等附加证据。对于本文任务，evaluator 需要组织数据读取、站点划分、baseline 运行、候选方案执行、指标计算和必要的有效性检查。Evaluator 在候选搜索开始前确定，从而避免系统为了适应某个候选结果而改变评价协议。

1.3 迭代式研究循环

在研究目标和 evaluator 确定后，Famou-Scientist 进入内层研究循环。设第 k 个目标下第 t 轮之前已经完成的实验历史为

$$\mathcal{H}_t^{(k)} = \{(a_i^{(k)}, e_i^{(k)})\}_{i=1}^{t-1}.$$

候选生成和评价过程为：

$$a_t^{(k)} \sim \pi_{\phi}(\cdot \mid \mathcal{G}^{(k)}, \mathcal{E}_{\mathcal{G}^{(k)}}, \mathcal{H}_t^{(k)}), \qquad e_t^{(k)} = \mathcal{E}_{\mathcal{G}^{(k)}}(a_t^{(k)}).$$

每一轮包含四个阶段。

提出想法。 系统根据当前研究目标、baseline、已有候选及历史实验结果提出新的解决机制。一个有效的想法应说明其改变了算法的哪一部分，以及为什么这种改变可能改善目标指标。搜索过程因此不局限于随机的超参数调整，也可以探索新的数据表示、特征构造、模型结构、训练策略和其他任务相关机制。历史实验还可以帮助系统识别已经尝试过的方向，减少重复搜索。

实现候选。 提出的解决机制被转换为可以运行的候选方案代码。候选程序遵守 benchmark 合约规定的输入输出约束，并使用统一的 evaluator，从而保证不同候选之间具有可比性。实现过程还需要检查候选是否能够在目标数据和预算内完成运行，并将实现失败与方案本身的低分结果区分开来。

运行与评价。 候选程序在固定的数据和评价协议下运行，系统记录其性能指标以及必要的实验诊断信息。候选方案可能取得较好的结果，也可能因为实现错误、资源超限或训练不稳定而失败。这些情况都被视为研究循环中的有效反馈。评价结果不仅包含一个最终分数，也包含能够帮助分析方案行为的中间证据。

分析与更新。 系统分析候选方案相对于 baseline 的结果，并据此决定下一轮是继续改进当前机制、探索新的方向，还是结合已有的多个机制。成功和失败的实验都会影响后续候选的生成，使研究过程从独立的单轮尝试转变为基于证据的连续搜索。

1.4 用户反馈驱动的外层循环

内层循环优化的是给定目标下的候选方案，但一轮搜索的结果也可能暴露出目标定义本身的问题。例如，候选方案在主要指标上提高，却没有改善用户真正关心的跨站点稳定性；选定的 benchmark 不能反映任务中的关键困难；或者结果已经表明原始问题需要加入新的约束。Famou-Scientist 允许用户在这种情况下直接提供反馈，而不必将后续工作限制在原始目标内。

设第 k 轮外层研究结束后，用户反馈为 f_k。系统结合当前目标和该反馈更新下一轮研究目标：

$$\mathcal{G}^{(k+1)} = \mathcal{U}_\phi(\mathcal{G}^{(k)}, f_k). \tag{3}$$

其中，$\mathcal{U}_\phi$ 表示目标修订过程。式 (3) 中的目标更新可以改变优化指标、数据范围、baseline、benchmark 或资源约束；如果这些变化影响评价含义，系统会相应地重新构造 evaluator。上一轮的候选、实验结果和失败分析不会被丢弃，而是作为新目标下继续研究时的历史证据。这样，系统形成“目标澄清—方案搜索—用户反馈—目标修订”的外层循环，以及其内部的候选方案搜索循环。

这种设计保留了用户对研究方向的控制，同时允许系统在每一轮中承担具体的方案探索工作。用户不需要在每次候选实现和实验运行之间手动介入，只需要在阶段性结果不足以回答原始问题时修订目标或评价重点。

1.5 异步并发研究基础设施

Famou-Scientist 的研究循环建立在支持异步并发执行的基础设施之上。候选生成、实现、实验运行和结果分析在逻辑上由同一个研究循环协调，但具体任务可以被调度到不同的执行资源上并行运行。对于同一轮提出的多个候选，系统可以同时进行实现和评价；对于资源需求不同的任务，也可以采用不同的执行队列，而不必让一个长时间运行的候选阻塞整个研究过程。

基础设施持续维护任务状态、运行日志、评价结果和候选之间的关联，使部分任务先完成时可以先进入分析阶段，失败任务也可以被隔离并返回诊断信息。对话层和执行层相互独立，因此

用户可以在后台实验运行期间继续提供反馈、暂停当前方向或修改外层目标。新的目标确认后，系统可以在保留既有证据的同时启动新的候选搜索。

这种异步并发能力使 Famou-Scientist 能够将有限的语言模型交互转化为较大规模的实验搜索，同时保持研究过程的连续性和可追溯性。对于本文的 MDD 任务，它允许多个候选方案在相同 benchmark 下并行比较，并将已完成的结果及时反馈给后续的算法分析和目标调整。

1.6 在跨站点 MDD 分类中的实例化

在本文中，用户首先提出跨站点 MDD 分类的研究目标。Famou-Scientist 通过目标澄清确定需要比较的任务定义、数据边界和泛化指标；当需要任务背景时，Deep Research 负责识别 MDD 静息态影像分类中常见的 baseline、跨站点 benchmark 和评价协议；在这些信息得到确认后，系统构造 evaluator，对 baseline 和搜索得到的候选方案执行一致的评价流程。候选方案空间 $\mathcal{A}$ 允许搜索不同的连接组表示、特征构造方式、模型结构、训练策略和其他任务相关机制。

Famou-Scientist 的任务不是在没有约束的情况下生成任意神经网络，而是在预先定义的科学问题、baseline 和评价边界内寻找具有更好跨站点泛化能力的分类程序。如果阶段性结果显示原始目标或评价协议需要调整，用户反馈可以触发外层目标更新，并开启新的研究循环。第五章将介绍具体的数据构建、benchmark、搜索范围和实验协议，第六章将报告研究循环实际发现的候选方案及其性能，并进一步分析哪些算法机制可能解释其跨站点表现。